

Gram Newton-Schulz: A Fast, Hardware-Aware Newton-Schulz Algorithm for Muon

Дарья Дядюкина Дарья Рудась
diadiukina.da@phystech.edu rudas.dv@phystech.edu

April 15, 2026

Abstract

Оптимизатор Muon показывает сильные результаты благодаря ортогонализированным обновлениям, однако остаётся вычислительно дорогим из-за шага Newton-Schulz. Авторы статьи [1] предлагают метод Gram Newton-Schulz, где получают ускорение за счёт работы с матрицами Грама, но поскольку статья вышла совсем недавно, остаются вопросы, связанные с устойчивостью и воспроизводимостью. Мы хотим проверить, действительно ли алгоритм является надёжным и обобщаемым, и исследовать поведение метода на других архитектурах. По сути, работа направлена на оценку того, можно ли сохранить преимущества Muon, существенно снизив его вычислительную стоимость без потери качества.

1 Идея

Цель проекта - исследовать и воспроизвести ускоренную модификацию оптимизатора Muon, основанную на методе Gram Newton-Schulz. В рамках проекта планируется разобраться в устройстве Muon, его основных ограничениях и предложенной модификации, уделив внимание проблемам численной устойчивости метода Gram Newton-Schulz и возможным способам стабилизации, таким как рестарты. Далее воспроизвести результаты статьи на моделях Llama-430M, Qwen-600M, Gemma-1B и MoE-1B, повторить авторские численные эксперименты и сравнить их как с базовой реализацией Muon, так и с широко используемым оптимизатором AdamW. Основной акцент будет сделан на сравнении качества обучения по шагам оптимизатора, где Muon ожидаемо должен превосходить AdamW, а также на сравнении стоимости шага ортогонализации, где Gram Newton-Schulz должен быть быстрее стандартного Newton-Schulz. Дополнительно планируется провести эксперименты на моделях меньшего и большего масштаба и, при возможности, выйти за пределы языковых моделей.

References

- [1] DAO Lab. Gram newton-schulz: A fast, hardware-aware newton-schulz algorithm for muon. <https://dao-lab.ai/blog/2026/gram-newton-schulz/>, 2026.