

Gram Newton-Schulz: A Fast, Hardware-Aware Newton-Schulz Algorithm for Muon

Дарья Дядюкина Дарья Рудась
diadiukina.da@phystech.edu rudas.dv@phystech.edu

April 26, 2026

Abstract

Оптимизатор Muon показывает сильные результаты благодаря ортогонализированным обновлениям, однако остаётся вычислительно дорогим из-за шага Newton-Schulz. Авторы статьи [?] предлагают метод Gram Newton-Schulz, где получают ускорение за счёт работы с матрицами Грама, но поскольку статья вышла совсем недавно, остаются вопросы, связанные с устойчивостью и воспроизводимостью. Мы хотим проверить, действительно ли алгоритм является надёжным и обобщаемым, и исследовать поведение метода на других архитектурах. По сути, работа направлена на оценку того, можно ли сохранить преимущества Muon, существенно снизив его вычислительную стоимость без потери качества.

1 Идея

Цель проекта - исследовать и воспроизвести ускоренную модификацию оптимизатора Muon, основанную на методе Gram Newton-Schulz. В рамках проекта планируется разобраться в устройстве Muon, его основных ограничениях и предложенной модификации, уделив внимание проблемам численной устойчивости метода Gram Newton-Schulz и возможным способам стабилизации, таким как рестарты. Далее воспроизвести результаты статьи на моделях Llama-430M, Qwen-600M, Gemma-1B и MoE-1B, повторить авторские численные эксперименты и сравнить их как с базовой реализацией Muon, так и с широко используемым оптимизатором AdamW. Основной акцент будет сделан на сравнении качества обучения по шагам оптимизатора, где Muon ожидаемо должен превосходить AdamW, а также на сравнении стоимости шага ортогонализации, где Gram Newton-Schulz должен быть быстрее стандартного Newton-Schulz. Дополнительно планируется провести эксперименты на моделях меньшего и большего масштаба и, при возможности, выйти за пределы языковых моделей.

1.1 Problem

Рассмотрим обучение нейронной сети с матрицей весов $W_k \in R^{n \times m}$ на шаге k . Пусть $\mathcal{L}(W)$ - функция потерь, $G_k = \nabla_W \mathcal{L}(W_k)$ - градиент. Как показано в [1], обновление Muon [2] является решением задачи наискорейшего спуска относительно операторной RMS→RMS нормы:

$$\Delta W^* = \arg \min_{\|\Delta W\|_{\text{RMS} \rightarrow \text{RMS}} \leq 1} \langle G_k, \Delta W \rangle, \quad (1)$$

решение которой имеет вид $\Delta W^* = -\text{polar}(G_k)$. Здесь $\text{polar}(X) = UV^\top$ при сингулярном разложении $X = U\Sigma V^\top$ - полярный фактор матрицы X .

С учётом импульса правило обновления Muon принимает вид:

$$M_k = \mu M_{k-1} + G_k, \quad (2)$$

$$W_{k+1} = W_k - \eta \cdot \text{polar}(M_k), \quad (3)$$

где μ - коэффициент импульса, η - шаг обучения, $M_0 = 0$.

Основной вычислительной сложностью Muon является шаг $\text{polar}(M_k)$, который необходимо выполнять на каждой итерации обучения. Точное вычисление полярного разложения через SVD стоит $O(mn^2)$,

Algorithm 1 Muon optimizer

```
1:  $M_0 \leftarrow 0$ 
2: for  $k = 0, 1, \dots, K - 1$  do
3:    $G_k \leftarrow \nabla_W \mathcal{L}(W_k)$  // вычисляем градиент
4:    $M_k \leftarrow \mu M_{k-1} + G_k$  // обновляем моментум
5:    $W_{k+1} \leftarrow W_k - \eta \cdot \text{polar}(M_k)$  // ортогонализированный шаг
6: end for
```

Algorithm 2 Standard Newton-Schulz

```
1:  $X \leftarrow X / (\|X\|_F + \epsilon)$  // нормализация с.з. в  $[0, 1]$ 
2:  $X \leftarrow \text{float16}(X)$ 
3: Если  $m < n$ :  $X \leftarrow X^\top$  // делаем  $XX^\top$  дешевле
4: for  $t = 1, \dots, 5$  do
5:    $A \leftarrow XX^\top$  //  $O(mn^2)$ 
6:    $B \leftarrow b_t A + c_t A^2$  //  $O(n^3)$ 
7:    $X \leftarrow a_t X + BX$  //  $O(mn^2)$ 
8: end for
9: Если  $m < n$ :  $X \leftarrow X^\top$ 
```

что слишком дорого. Поэтому на практике используется итерация Ньютона-Шульца - итеративный полиномиальный метод приближения $\text{polar}(X)$.

Каждая итерация содержит нечётный полином $p_t(x) = a_t x + b_t x^3 + c_t x^5$, преобразующий сингулярные значения. Если $X_0 = U\Sigma V^\top$, то $X_T = U \cdot (p_T \circ \dots \circ p_1)(\Sigma) \cdot V^\top$. При $(p_T \circ \dots \circ p_1)(x) \approx 1$ получаем $X_T \approx UV^\top = \text{polar}(X)$. Каждая итерация содержит три GEMM: два дорогих прямоугольных умножения $XX^\top$ и BX стоимостью $2mn^2$ каждое, а также квадратное A^2 стоимостью $2n^3$. Итого $3T$ GEMM операций общей стоимостью $2T(2\alpha + 1)n^3$ FLOPs, где $\alpha = m/n \geq 1$ - соотношение сторон, из которых $2T$ - дорогие прямоугольные. При использовании симметричных GEMM для $XX^\top$ и A^2 стоимость снижается до $T(3\alpha + 1)n^3$. При $T = 5$, $\alpha = 4$ это составляет $90n^3$ без симметричных ядер и $65n^3$ с ними. В современных MoE-архитектурах α достигает 4-8, что делает прямоугольные умножения доминирующими.

Авторы [3] предлагают сократить число дорогих прямоугольных умножений, опираясь на тождество $\text{polar}(X) = (XX^\top)^{-1/2}X$, которое выводится следующим образом. Полиномы итерации NS нечётны, значит можно их представить как

$$p_t(x) = x \cdot h_t(x^2), \quad h_t(x) = a_t + b_t x + c_t x^2. \quad (4)$$

Это означает, что действие p_t на сингулярное значение x можно разложить на два независимых процесса: эволюцию квадрата $r = x^2$ и накопление множителя $q = x/x_0$, не храня промежуточное x явно. Определим итерацию:

$$z_t = h_t(r_{t-1}), \quad r_t = r_{t-1} \cdot z_t^2, \quad q_t = q_{t-1} \cdot z_t, \quad (5)$$

с начальными условиями $r_0 = x_0^2$, $q_0 = 1$.

Теорема 1 ([3], Theorem 1) Пусть $p_t(x) = x \cdot h_t(x^2)$ - нечётные полиномы и $\{r_t, q_t\}$ определены в (5). Тогда

$$(p_T \circ \dots \circ p_1)(x_0) = q_T \cdot x_0, \quad q_T \rightarrow r_0^{-1/2} \text{ при } T \rightarrow \infty.$$

На матричном уровне это даёт переход от итерирования на прямоугольной $X \in R^{n \times m}$ к итерированию на квадратной матрице Грама $XX^\top \in R^{n \times n}$. Используя тождество $\text{polar}(X) = (XX^\top)^{-1/2}X$, вся процедура сводится к:

1. Вычисление $R_0 = XX^\top \in R^{n \times n}$;
2. Итерирование (5) на квадратных матрицах, получив $Q_T \approx (XX^\top)^{-1/2}$;
3. Вычисление $\text{polar}(X) \approx Q_T \cdot X$.

Шаги 1 и 3 требуют по одному прямоугольному умножению $O(mn^2)$, основной цикл (шаг 2) работает только с квадратными $n \times n$ матрицами стоимостью $O(n^3)$.

Algorithm 3 Stabilized Gram Newton-Schulz

```
1:  $X \leftarrow X / (\|X\|_F + \epsilon)$ 
2:  $X \leftarrow \text{float16}(X)$ 
3:  $R_0 \leftarrow XX^\top$  // матрица Грама,  $O(mn^2)$ 
4:  $Q_0 \leftarrow I$ 
5: for  $t = 1, \dots, T$  do
6:   Если  $t = 3$ : // рестарт
7:      $X \leftarrow Q_2X$ ;  $R_2 \leftarrow XX^\top$ ;  $Q_2 \leftarrow I$ 
8:      $Z_t \leftarrow b_t R_{t-1} + c_t R_{t-1}^2$  //  $O(n^3)$ 
9:      $Q_t \leftarrow Q_{t-1}Z_t + a_t Q_{t-1}$  //  $O(n^3)$ 
10:     $(RZ)_t \leftarrow R_{t-1}Z_t + a_t R_{t-1}$  //  $O(n^3)$ 
11:     $R_t \leftarrow Z_t(RZ)_t + a_t(RZ)_t$  //  $O(n^3)$ 
12:  end for
13:  $X \leftarrow Q_T X$  // результат,  $O(mn^2)$ 
```

Хотя Gram NS математически эквивалентен стандартному NS в точной арифметике, в half-precision он ведёт себя иначе. Вычисление матрицы Грама $R_0 = XX^\top$ немедленно возводит число обусловленности в квадрат, и из-за ошибок округления у R_t возникают ложные отрицательные собственные значения. Поскольку правило обновления $r_t = r_{t-1} \cdot h_t(r_{t-1})^2$ не может вычислить квадратный корень отрицательного числа, амплитуда ложных собственных значений растёт экспоненциально, приводя к расходимости. Эмпирически найденное решение - рестарт после итерации 2: пересчёт $R = XX^\top$ из текущего приближения $X \leftarrow Q_2X$ устраняет накопленные ложные собственные значения ценой двух дополнительных прямоугольных GEMM.

Каждая итерация основного цикла содержит 4 симметричных GEMM стоимостью $4n^3$. Инициализация $R_0 = XX^\top$ и вывод $Q_T X$ добавляют 2 прямоугольных GEMM. С учётом оптимизаций итого 19 GEMM общей стоимостью $(4T + 3\alpha - 3)n^3$ FLOPs, из которых лишь 2 прямоугольные. При $T = 5$, $\alpha = 4$ это $29n^3$ - экономия 55% по сравнению со стандартным NS с симметричными ядрами и 68% - без них. Стабилизация через рестарт добавляет ещё 2 прямоугольных GEMM (Q_2X и пересчёт $XX^\top$), но экономит 3 квадратных. Итого 18 GEMM общей стоимостью $(4T + 6\alpha - 6)n^3$ FLOPs, из которых 4 - прямоугольные. При $T = 5$, $\alpha = 4$ это $38n^3$ - экономия 42% по сравнению со стандартным NS с симметричными ядрами и 58% - без них.

2 Outcomes

Конкретными выходами проекта будут:

1. Воспроизведение результатов статьи с использованием AdamW, Muon с Newton Schulz и Muon с Gram Newton-Schulz на моделях Llama-430M, Qwen-600M, Gemma-1B и MoE-1B.
2. Анализ численной стабильности, графики эволюции собственных значений промежуточных матриц R_t , Q_t в bf16 и fp16, демонстрирующие эффект ложных отрицательных собственных значений и влияние рестарта.
3. При возможности будут проведены численные эксперименты на моделях меньшего и большего масштаба, а также за пределами языковых моделей.

Код экспериментов доступен по ссылке: <https://github.com/DyaDasha/Gram-Newton-Schulz>.

3 Литературный обзор

Оптимизатор Muon был предложен в [2] как альтернатива AdamW [4] для обучения скрытых слоёв нейронных сетей. Его ключевая идея - замена градиента на ортогонализированную матрицу $\text{polar}(M_k)$, полученную через полярное разложение матрицы момента.

Теоретическое обоснование Muon дано в блоге Бернштейна [1], где показано, что обновление Muon является решением задачи наискорейшего спуска относительно операторной $\text{RMS} \rightarrow \text{RMS}$ нормы. Этот подход обобщён в работе [5], где авторы систематически исследуют влияние выбора операторной нормы на конструкцию оптимизаторов.

Для приближённого вычисления $\text{polar}(X)$ Muon использует итерацию Ньютона-Шульца - классический метод из численной линейной алгебры. В работе Polar Express [6] авторы оптимизируют полиномиальные коэффициенты этой итерации, добиваясь более быстрой сходимости при том же числе шагов.

Масштабируемость Muon для обучения больших языковых моделей подтверждена в [7], где авторы показали его применимость при обучении моделей масштаба миллиардов параметров. Практическая значимость Muon продемонстрирована его использованием при обучении моделей Kimi K2 [8] - MoE-модели с триллионом параметров.

Альтернативные подходы к предобуславливанию второго порядка включают оптимизатор Shampoo [9] и его модификацию SOAP [10], которая комбинирует блочное предобуславливание с механизмами стабилизации Adam. Однако, в отличие от Muon, эти методы не используют полярное разложение.

Ключевая работа для данного проекта - блогпост Gram Newton-Schulz [3], опубликованный в апреле 2025 года. Это новая, ещё не рецензированная работа, в которой авторы предлагают переформулировать итерацию Ньютона-Шульца через матрицу Грама XX^T , сокращая число прямоугольных матричных умножений с 10 до 4 и достигая экономии 42-58% FLOPs. Авторы также выявляют проблему численной нестабильности в half-precision и предлагают эмпирически найденное решение через стратегию рестарта. Авторы предоставляют открытый код в репозитории [Dao-AILab/gram-newton-schulz](https://github.com/Dao-AILab/gram-newton-schulz), однако воспроизведение результатов на архитектурах и масштабах, отличных от рассмотренных в блогпосте, остаётся открытым вопросом.

4 Метрики качества

Для оценки результатов проекта будут использоваться следующие формальные метрики:

1. Validation perplexity. Основная метрика качества обучения языковой модели. Воспроизведение считается успешным, если разница между Muon (стандартный NS) и GramMuon (Gram NS) составляет ≤ 0.01 , как заявлено авторами [3].

2. Ускорение шага ортогонализации. Wall-clock время шага Newton-Schulz:

$$\text{Speedup} = \frac{t_{\text{standard NS}}}{t_{\text{Gram NS}}} \quad (6)$$

3. Число FLOPs.

4. Дефект ортогональности. Насколько матрица далека от единичной при перемножении ее с транспонированной

5. Максимальная поэлементная разница между выходами NS и GramNS

6. Относительная ошибка до точного polar через SVD

$$\frac{\|X_{\text{approx}} - X_{\text{exact}}\|}{\|X_{\text{exact}}\|} \quad (7)$$

5 Примерный план

- 20-26 апреля: Разбор теории Muon, Newton-Schulz, Gram NS. Изучение блогпоста [1] и статьи [3]. Оформление project proposal. Запуск кода авторов из репозитория [Dao-AILab/gram-newton-schulz](https://github.com/Dao-AILab/gram-newton-schulz), проверка корректности на синтетических матрицах и работа с бенчмарком.
- 26 апреля - 5 мая: Воспроизведение численных результатов статьи: обучение Llama-430M, Qwen-600M, Gemma-1B и MoE-1B с Muon (стандартный NS), GramMuon (Gram NS) и AdamW. Сравнение validation perplexity и wall-clock ускорения шага ортогонализации.
- 5-10 мая: Анализ численной стабильности. Эксперименты на моделях меньшего и большего масштаба (при наличии ресурсов). Подготовка черновика постера.
- 10-17 мая: Финальные эксперименты, оформление постера, подготовка к защите.

Программа минимум: воспроизвести ускорение шага ортогонализации и подтвердить сохранение validation perplexity на моделях из статьи (Llama-430M, Qwen-600M).

Программа максимум: эксперименты на моделях других масштабов и архитектур, при возможности - выход за пределы языковых моделей.

6 Отчёт о фазе прототипирования

На данном этапе мы выполнили следующие шаги:

1. Запуск кода авторов из репозитория [Dao-AILab/gram-newton-schulz](https://github.com/Dao-AILab/gram-newton-schulz).
2. Изучены статья Gram Newton-Schulz [3] и научный ландшафт вокруг поставленной задачи
3. Написан research proposal
4. Проведены эксперименты на бенчмарке ортогонализации

Family	Shape	Samples	Std defect	Gram defect	Std vs SVD	Gram vs SVD
gaussian	128×128	5	0.1848744	0.1848744	0.09829205	0.09829205
gaussian	64×256	5	0.1689057	0.1689057	0.08606504	0.08606503
gaussian	256×64	5	0.1694116	0.1694115	0.08612700	0.08612700
ill_conditioned	128×128	5	0.7340742	0.7340742	0.6872154	0.6872154
ill_conditioned	64×256	5	0.7193759	0.7193759	0.6718758	0.6718759
low_rank	128×256	5	0.9691466	0.9691466	0.9465750	0.9465750

Table 1: Проверка корректности стандартного Newton-Schulz и Gram Newton-Schulz на синтетических матрицах на устройстве MPS в формате FP32.

Family	Shape	Samples	Std defect	Gram defect	Std vs SVD	Gram vs SVD
gaussian	128×128	5	0.1849028	0.1849028	0.09833728	0.09833728
gaussian	64×256	5	0.1689101	0.1689101	0.08606797	0.08606796
gaussian	256×64	5	0.1694088	0.1694089	0.08612596	0.08612602
ill_conditioned	128×128	5	0.7340171	0.7340171	0.6872683	0.6872683
ill_conditioned	64×256	5	0.7191431	0.7191431	0.6721476	0.6721476
low_rank	128×256	5	0.9689487	0.9689487	0.9466793	0.9466793

Table 2: Проверка корректности стандартного Newton-Schulz и Gram Newton-Schulz на синтетических матрицах на устройстве MPS в формате FP16.

Dtype	Shape	Standard, ms	Gram, ms	Speedup	Std defect	Gram defect
FP32	128×512	0.6509	0.8762	0.743	0.167148	0.167148
FP32	512×2048	7.9877	4.6093	1.733	0.186657	0.186657
FP16	128×512	1.2018	2.3194	0.518	0.167070	0.165976
FP16	512×2048	5.7794	4.2484	1.360	0.186690	0.186167

Table 3: Сравнение времени работы стандартного Newton-Schulz и Gram Newton-Schulz на устройстве MPS. Значение speedup больше 1 означает преимущество Gram Newton-Schulz.

На синтетических матрицах Gram Newton-Schulz численно воспроизводит стандартный Newton-Schulz: на прямоугольных матрицах расхождение между методами составляет порядка $1e-6$ в fp32 и остаётся малым в fp16. На MPS выигрыш по времени зависит от размера матрицы: для сравнительно небольших матриц (128x512) Gram-подход медленнее baseline, однако для более крупных прямоугольных матриц (512x2048) он даёт ускорение до 1.73x в fp32 и 1.36x в fp16. Это показывает, что Gram Newton-Schulz является хорошим улучшением Newton-Schulz именно в крупномасштабном прямоугольном режиме, характерном для матричных обновлений Muon

Dtype	Family	Shape	Std-Gram max abs diff
FP32	gaussian	128×128	0
FP32	gaussian	64×256	2.503395×10^{-6}
FP32	gaussian	256×64	2.428889×10^{-6}
FP32	ill_conditioned	128×128	0
FP32	ill_conditioned	64×256	3.285706×10^{-5}
FP32	low_rank	128×256	8.720905×10^{-6}
FP16	gaussian	128×128	0
FP16	gaussian	64×256	1.788139×10^{-6}
FP16	gaussian	256×64	2.488494×10^{-6}
FP16	ill_conditioned	128×128	0
FP16	ill_conditioned	64×256	4.152302×10^{-5}
FP16	low_rank	128×256	8.963048×10^{-6}

Table 4: Максимальное абсолютное расхождение между стандартным Newton–Schulz и Gram Newton–Schulz на синтетических матрицах.

family	Как генерируется	Что проверяет
gaussian	Случайная матрица с элементами из нормального распределения	Базовый типичный случай для проверки качества ортогонализации
ill_conditioned	Матрица с сильно различающимися сингулярными числами	Численную устойчивость на плохо обусловленных матрицах
low_rank	Почти низкоранговая матрица: low-rank структура плюс малый шум	Поведение на почти вырожденных матрицах

Table 5: Типы синтетических матриц, использованных в экспериментах.

References

- [1] Jeremy Bernstein. Deriving muon, 2025.
- [2] Keller Jordan, Yuchen Jin, Vlado Boza, Jiacheng You, Franz Cesista, Laker Newhouse, and Jeremy Bernstein. Muon: An optimizer for hidden layers in neural networks, 2024.
- [3] Jack Zhang, Noah Amsel, Berlin Chen, and Tri Dao. Gram newton-schulz: A fast, hardware-aware newton-schulz algorithm for muon, 2026.
- [4] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*, 2019.
- [5] Jeremy Bernstein and Laker Newhouse. Old optimizer, new norm: An anthology. *arXiv preprint arXiv:2409.20325*, 2024.
- [6] Noah Amsel, David Persson, Christopher Musco, and Robert M. Gower. The polar express: Optimal matrix sign methods and their application to the muon algorithm. In *International Conference on Learning Representations (ICLR)*, 2026.
- [7] Jingyuan Liu et al. Muon is scalable for llm training. *arXiv preprint arXiv:2502.16982*, 2025.
- [8] Kimi Team. Kimi k2: Open agentic intelligence. *arXiv preprint arXiv:2507.20534*, 2026.
- [9] Vineet Gupta, Tomer Koren, and Yoram Singer. Shampoo: Preconditioned stochastic tensor optimization. 2018.
- [10] Nikhil Vyas, Depen Morwani, Rosie Zhao, Mujin Kwun, Itai Shapira, David Brandfonbrener, Lucas Janson, and Sham Kakade. Soap: Improving and stabilizing shampoo using adam. *arXiv preprint arXiv:2409.11321*, 2024.